

Compte-Rendu de Soutenance

MSPR 2 -- MECHA Predict

Maintenance Predictive Industrielle par Intelligence Artificielle

Certification : RNCP35584 -- Expert en Informatique et Systeme d'Information

Bloc 4 : Concevoir et developper des solutions applicatives metier

Reference : MSPR TPRE841

Equipe : Malek El Fayedh, Thibaut Doreau, Vincent Goncalves, Pierre-Louis Guinel

Formation : EPSI -- Promotion 2026

Date : Mai 2026

Repository : github.com/HASHT85/MSPR2-MECHA

Compte-Rendu de Soutenance — MSPR 2 MECHA Predict

Certification : RNCP35584 — Expert en Informatique et Systeme d'Information

Bloc 4 : Concevoir et developper des solutions applicatives metier et specifiques

Reference : MSPR TPRE841

Date : Mai 2026

Equipe : Malek El Fayedh, Thibaut Doreau, Vincent Goncalves, Pierre-Louis Guinel

Formation : EPSI — Promotion 2026

Table des matieres

1. Contexte et problematique industrielle
 2. Collecte des besoins metiers (C1)
 3. Architecture de la solution (C2)
 4. Pipeline de donnees et feature engineering
 5. Modelisation et intelligence artificielle (C3)
 6. AMDEC — Analyse des Modes de Defaillance
 7. Solution applicative integree (C4)
 8. Tests et validation (C5)
 9. Integration continue (C6)
 10. Documentation et conforme (C7)
 11. Conduite du changement (C8)
 12. Conforme reglementaire — RGPD et EU AI Act
 13. Plan de deploiement multi-sites
 14. Bilan et perspectives
 15. Annexes
-

1. Contexte et problematique industrielle

1.1 Presentation de l'entreprise MECHA

MECHA est un groupe industriel fictif specialise dans la fabrication discrete de pieces mecaniques de haute precision, destinees aux secteurs de l'aeronautique (60% du chiffre d'affaires) et de l'automobile (40%). Le groupe exploite **5 usines** reparties entre la France et l'Espagne, totalisant **50 machines industrielles** equipees de capteurs IoT.

Site	Ville	Pays	Machines	Specialite	Date d'ouverture
USN-FR-01	Lyon	France	10	Aeronautique + Automobile (siege)	Mars 2018
USN-FR-02	Toulouse	France	10	Aeronautique	Juin 2019
USN-FR-03	Nantes	France	10	Aeronautique	Janvier 2021
USN-ES-01	Barcelone	Espagne	10	Automobile	Septembre 2022
USN-ES-02	Madrid	Espagne	10	Automobile	Avril 2023

Le modele economique repose sur des contrats pluriannuels avec des constructeurs automobiles europeens, des équipementiers et des acteurs aeronautiques de rang 1 et 2. Les exigences clients portent sur la tracabilite complete, les indicateurs de performance (taux de rebuts, disponibilite machines, temps de cycle) et la reactivite aux derives qualite. Les normes applicables sont EN 9100 pour l'aeronautique et IATF 16949 pour l'automobile.

1.2 Problematique identifiee

L'analyse conduite en MSPR 1 a permis d'identifier les problematiques suivantes :

Probleme	Criticite	Impact
Donnees dispersees entre systemes SCADA, MES et ERP	Critique	Impossible d'avoir une vision consolidee
Absence de detection precoce des derives machines	Critique	12 a 18 arrêts non planifiés par mois
Pas d'alertes operationnelles unifiees	Majeur	Delai detection-intervention de 4 a 8 heures
Aucun modele predictif deploye	Majeur	70% de maintenance curative
Indicateurs non standardises entre les 5 sites	Moyen	Comparaison inter-sites impossible

Chiffres cles de la situation actuelle :

- Budget maintenance annuel : 2,4 millions d'euros (8% du chiffre d'affaires)
- Repartition : 70% curatif / 25% preventif / 5% predictif
- Disponibilite machines : 87-88% (objectif secteur : 95%)
- Cout d'un arret non planifie : 5 000 a 15 000 euros (jusqu'a 30 000 euros en aeronautique)
- Penalites l'annee precedente : 180 000 euros (3 penalites contractuelles)
- Stock de pieces : 200 000 euros dont 30% inutilise

1.3 Objectifs du projet MSPR 2

La MSPR 2 constitue le passage du cadrage et de l'etude de faisabilite (MSPR 1) a la conception et la realisation concrete d'un prototype fonctionnel. Les objectifs sont les suivants :

Indicateur	Situation actuelle	Objectif vise
Temps d'arret non planifie	Environ 12h par mois	Inferieur a 4h par mois
Taux de pannes critiques	Environ 8%	Inferieur a 3%
Precision des predictions	0% (aucun modele)	Superieur a 90%
Repartition maintenance	70% curatif	50% predictif
Disponibilite machines	87-88%	Superieur a 95%
ROI estime	—	200 000 a 300 000 euros par an

1.4 Continuite avec la MSPR 1

Les recommandations formulees en MSPR 1 ont ete systematiquement prises en compte en MSPR 2 :

Recommandation MSPR 1	Action MSPR 2	Statut
Ameliorer le rappel du Random Forest (F1=71%)	Seuil abaisse a 0.3, features temporelles ajoutees, F1 passe a 76.3%	Appliquee
Ajouter des features temporelles (moyenne mobile, tendance)	6 features enrichies (temp_rolling_10min, temp_trend_1h, etc.)	Appliquee
Tester XGBoost	XGBoost entraine et compare (F1=75.9%, AUC=90.5%)	Appliquee
Exclure machine_status (data leakage)	Exclu du pipeline ML, test anti-leakage automatise	Appliquee
Documenter unites et encodages	Dictionnaire de donnees complet (data_dictionary.md)	Appliquee
Enrichir donnees contextuelles	Ligne production, type piece, profil machine ajoutees	Appliquee
Human-in-the-Loop pour EU AI Act	Mention explicite dans dashboard et API	Appliquee
Conteneuriser la solution	Docker Compose avec 4 services	Appliquee
Integration continue	GitHub Actions (lint, test, build)	Appliquee
Deploiement progressif	Plan 4 phases sur 12 mois documente	Appliquee
Conduite du changement	Document complet avec 4 axes et modeles de reference	Appliquee

2. Collecte des besoins metiers (C1)

2.1 Methodologie de collecte

La collecte des besoins a ete realisee par un entretien semi-directif de 2 heures 30 avec deux representants de la Direction Industrielle MECHA :

- **M. Jean-Pierre Duval** — Directeur Industriel (commanditaire du projet)
- **Mme Sophie Martin** — Responsable Maintenance de l'usine de Lyon

Le questionnaire a ete structure en 6 axes thematiques (A a F) comprenant 24 questions :

- Axe A : Organisation et processus actuels
- Axe B : Donnees et systemes d'information
- Axe C : Besoins fonctionnels
- Axe D : Contraintes et exigences
- Axe E : Attentes et criteres de succes
- Axe F : Deploiement et changement

2.2 Besoins fonctionnels identifies

L'entretien a permis d'identifier 10 besoins fonctionnels, priorises selon la methode MoSCoW :

Ref.	Besoin	Priorite
BF-01	Dashboard consolide multi-sites avec KPIs temps reel	Must
BF-02	Alertes automatiques sur derives machines	Must
BF-03	Prediction de pannes avec estimation du delai	Must
BF-04	Historique de maintenance consultable	Must
BF-05	Comparaison inter-sites (benchmark)	Must
BF-06	Detection d'anomalies comportementales	Must
BF-07	Indicateurs de degradation par machine	Must
BF-08	Reporting mensuel automatise	Should
BF-09	Integration future avec GMAO	Should
BF-10	Application mobile pour techniciens terrain	Should

2.3 Besoins non-fonctionnels

Ref.	Exigence	Seuil
BNF-01	Disponibilite du systeme	Superieur ou egal a 99.5%
BNF-02	Temps de reponse interface	Inferieur a 3 secondes
BNF-03	Hebergement des donnees	Europe (RGPD)
BNF-04	Tracabilite des actions	Complete (normes aeronautiques)
BNF-05	Scalabilite	50 a 200 machines
BNF-06	Securite	Authentification, chiffrement
BNF-07	Simplicité d'utilisation	Formation inferieure a 4 heures


2.4 Verbatim cle du commanditaire

"Le succes, c'est quand mes responsables maintenance me diront : 'je ne peux plus travailler sans cet outil.'" — M. Duval, Directeur Industriel

3. Architecture de la solution (C2)

3.1 Architecture en 7 couches

L'architecture retenue est une architecture en couches, distribuee et tolerante aux pannes, concue pour un environnement industriel :



Architecture en 7 couches MECHA Predict

3.2 Justification des choix techniques

Chaque composant a fait l'objet d'un comparatif documente avec au minimum 3 alternatives :

Composant	Choix retenu	Alternatives evaluees	Critere decisif
Langage	Python 3.11	R, Java, Julia	Ecosysteme ML + API unifie, competences equipe
Framework ML	scikit-learn	TensorFlow, PyTorch, H2O.ai	Modeles interpretables, prototypage rapide, donnees tabulaires
Classification	Random Forest	SVM, Regression logistique	Robuste, interpretable, peu de pretraitement
Regression RUL	XGBoost	LSTM, SVR	Performance elevee, gestion donnees manquantes
Framework API	FastAPI	Flask, Django REST, Express.js	Performance (15k req/s), doc Swagger native, validation Pydantic
Dashboard analytique	Streamlit	Dash, Metabase, Power BI	Prototypage Python, integration ML native
Monitoring temps reel	Grafana	Kibana, Datadog	Standard industriel, alerting natif, connexion PostgreSQL
Base de donnees	PostgreSQL 16	MongoDB, InfluxDB, TimescaleDB	Polyvalent, extensible, ACID, connexion Grafana native
Conteneurisation	Docker + Compose	Kubernetes, VM, Podman	Simple, reproductible, adapte a l'echelle du PoC
CI/CD	GitHub Actions	Jenkins, GitLab CI, CircleCI	Integration native GitHub, zero infrastructure

3.3 Strategie a deux dashboards — Evolution MSPR 2

En MSPR 1, Grafana a ete retenu comme unique outil de restitution. En MSPR 2, Streamlit a ete ajoute comme couche d'analyse complementaire :


Besoin	Grafana	Streamlit
Monitoring temps reel des capteurs	Excellent	Limite (pas de refresh auto)
Alertes operationnelles (email/Slack)	Natif	Non supporte
Exploration interactive des donnees	Limite (SQL fige)	Filtres dynamiques Python
Visualisation des predictions ML	Pas d'integration ML	Chargement natif des modeles scikit-learn
Comparaison de modeles (F1, AUC-ROC)	Non supporte	Courbes ROC, matrice de confusion
Feature importance et explicabilite IA	Non supporte	Graphiques interactifs
Vue consolidee multi-sites avec drill-down	Limite (variables)	Navigation Groupe, Site, Machine

3.4 Dimensionnement

Metrique	Pilote (Lyon)	Complet (5 sites)
Machines monitorees	10	50
Mesures par jour	864 000	4 320 000
Volume BDD par mois	2 Go	10 Go
Predictions par jour	240	1 200
Utilisateurs simultanes	5 a 10	30 a 50

3.5 Schema de la base de donnees

La base PostgreSQL comprend 4 tables et 1 vue materialisee :



Schema de la base de donnees MECHA

9 index ont ete crees pour optimiser les requetes frequentes (par machine, par usine, par timestamp, par statut de maintenance).

4. Pipeline de donnees et feature engineering

4.1 Construction du dataset hybride

Le dataset final combine deux sources de donnees :

Source 1 — Dataset MECHA simule (100 000 enregistrements)

- 50 machines (IDs 1 a 50) reparties sur 5 usines
- Periode : a partir du 1er janvier 2025
- 2 000 enregistrements par machine
- Simulation realiste : cycle journalier (production 6h-22h, arret la nuit), degradation progressive, surchauffe, reparations

Source 2 — Dataset AI4I 2020 Predictive Maintenance (10 000 enregistrements)

- Provenance : UCI Machine Learning Repository / Kaggle
- 10 000 enregistrements issus de machines reelles
- Machines IDs 51 a 100
- Harmonisation des colonnes : temperature Kelvin vers Celsius, vitesse rotationnelle vers vibration, types de pannes adaptes au contexte MECHA

Dataset final : 110 000 enregistrements, 30 colonnes, 100 machines, 5 usines

4.2 Profils de machines

L'heterogeneite du parc industriel a ete modelisee par 4 profils distincts :

Profil	Temperature de base	Vibration de base	Probabilite de panne	Probabilite maintenance preventive
Robuste	70 degres C	35 mm/s	2%	5%
Standard	75 degres C	40 mm/s	4%	8%
Fragile	82 degres C	50 mm/s	8%	12%
Vieillissante	85 degres C	55 mm/s	10%	15%

4.3 Feature engineering

6 features enrichies ont ete ajoutees conformement aux recommandations de la MSPR 1 :

Feature	Formule	Justification
temp_rolling_10min	Moyenne mobile temperature (fenetre 10 min)	Lisser le bruit des capteurs
temp_trend_1h	Pente lineaire de la temperature (fenetre 1h)	Detecter une montee progressive
vibr_rolling_10min	Moyenne mobile vibration (fenetre 10 min)	Lisser les pics ponctuels
temp_std_30min	Ecart-type temperature (fenetre 30 min)	Detecter l'instabilite
energy_vibr_ratio	Rapport energie / vibration	Correlations croisees
downtime_risk	$0.3 \times \text{temp_risk} + 0.25 \times \text{vibr_risk} + 0.45 \times \text{rul_risk}$	Score composite de risque d'arret

4.4 Variables les plus predictives

L'analyse des correlations avec la variable cible `maintenance_required` a revele :

Variable	Correlation	Interpretation
predicted_remaining_life	-0.34 (tres forte)	Plus le RUL diminue, plus le risque augmente
temperature	+0.28 (forte)	Temperature elevee = indicateur de panne
vibration	+0.11 (moderee)	Vibrations anormales = usure mecanique
humidity	~0.00 (nulle)	Non informative
pressure	~0.00 (nulle)	Non informative

4.5 Dictionnaire de donnees

Un dictionnaire de donnees complet (`data_dictionary.md`) documente les 30 colonnes du dataset, incluant pour chaque variable : le type, la plage de valeurs, l'unite, la source et la correlation avec la variable cible. Les 9 hypotheses de simulation sont egalement documentees.

5. Modelisation et intelligence artificielle (C3)

5.1 Strategie de modelisation

Trois types de problemes de maintenance predictive sont couverts :

Probleme	Type	Modele	Sortie
"Cette machine va-t-elle tomber en panne ?"	Classification binaire	Random Forest, XGBoost, Regression Logistique	0 (normal) / 1 (maintenance requise) + probabilite
"Dans combien de temps ?"	Regression	RF Regressor RUL	Nombre d'heures estimees avant panne
"Le comportement est-il anormal ?"	Detection d'anomalies	Isolation Forest	Score d'anomalie + severite

5.2 Protocole d'entrainement

Split temporel 80/20 : Les donnees sont trieess par timestamp. Les 80% les plus anciennes constituent le jeu d'entrainement (88 000 enregistrements), les 20% les plus recentes constituent le jeu de test (22 000 enregistrements). Ce choix evite le data leakage temporel qu'un split aleatoire aurait introduit.

Features utilisees (12) : temperature, vibration, humidity, pressure, energy_consumption, predicted_remaining_life, temp_rolling_10min, temp_trend_1h, vibr_rolling_10min, temp_std_30min, energy_vibr_ratio, downtime_risk

Variable exclue : `machine_status` — cette variable a ete identifiee en MSPR 1 comme source de data leakage. Un test automatisé verifie son exclusion.

Gestion du desequilibre : La classe positive (maintenance requise) represente seulement 3.1% des echantillons (908 sur 22 000 dans le jeu de test). Deux techniques sont appliquees :

- Random Forest : parametre `class_weight='balanced'`
- XGBoost : parametre `scale_pos_weight` calcule automatiquement (ratio negatifs/positifs)

Reproductibilite : `RANDOM_STATE=42` pour tous les modeles

5.3 Resultats des 5 modeles

Modeles de classification

Metrique	Random Forest	XGBoost	Regression Logistique
Accuracy	98.4%	98.4%	90.5%
Precision	98.8%	97.9%	27.3%
Recall	62.1%	62.0%	79.2%
F1-Score	76.3%	75.9%	40.6%
AUC-ROC	0.898	0.905	0.868
Faux positifs	7	12	1 912
Faux negatifs	344	345	189
Vrais positifs	564	563	719

Analyse : Le Random Forest et le XGBoost atteignent des performances quasi-identiques. Le Random Forest est retenu comme modele principal en raison de sa meilleure interpretabilite (feature importance native). Le XGBoost sert de modele de secours (meilleur AUC-ROC : 0.905 contre 0.898).

La Regression Logistique sert de baseline. Son recall eleve (79.2%) mais sa precision tres faible (27.3%) la rendent inutilisable en production (trop de fausses alertes).

Modele de detection d'anomalies

Metrique	Isolation Forest
Accuracy	74.7%
Precision	9.5%
Recall	59.7%
AUC-ROC	0.774
Anomalies detectees	5 735
Contamination effective	26.1%

L'Isolation Forest, en tant que modele non supervise, a une precision faible mais permet de detecter des comportements atypiques sans labels prealables. Il est utilise en complement des modeles supervises.

Modele de regression RUL

Metrique	RF Regressor RUL
MAE	39.25 heures
RMSE	69.28 heures
R-carre	0.598 (59.8%)
MSE	4 799.84

Le modele RUL predit le temps restant avant defaillance avec une erreur moyenne de 39 heures. La categorisation est : urgent (inferieur a 24h), soon (inferieur a 72h), moderate (inferieur a 168h), safe (superieur ou egal a 168h).

5.4 Progression MSPR 1 vers MSPR 2

Modele	F1 MSPR 1	F1 MSPR 2	Progression
Random Forest	71.0%	76.3%	+5.3 points
Isolation Forest	38.2%	16.3%	-21.9 points (desequilibre accru)
Regression Logistique	47.2%	40.6%	-6.6 points (baseline)
XGBoost	Non teste	75.9%	Nouveau
RF Regressor RUL	Non teste	R-carre=59.8%	Nouveau

L'objectif MSPR 1 de F1 superieur ou egal a 75% est atteint pour le Random Forest (76.3%).

5.5 Top 3 des features les plus importantes

1. `predicted_remaining_life` — 37% d'importance
2. `downtime_risk` — 20% d'importance
3. `temp_rolling_10min` — 14% d'importance

5.6 Model Cards (conformite EU AI Act)

Chaque modele dispose d'une Model Card documentant : les hyperparametres, les metriques, les limites, les biais identifies, la classification EU AI Act (risque limite), les conditions de maintenance (reexamen trimestriel, reentrainement si baisse F1 superieure a 5%).

6. AMDEC — Analyse des Modes de Defaillance

6.1 Presentation de la demarche

L'AMDEC (Analyse des Modes de Defaillance, de leurs Effets et de leur Criticite) est une methode systematique d'analyse des risques utilisee dans l'industrie pour identifier les defaillances potentielles, evaluer leur gravite et definir des actions preventives. Dans le contexte de MECHA Predict, l'AMDEC est appliquee a deux niveaux :

- **Niveau machine** : analyse des modes de defaillance des equipements industriels
- **Niveau systeme IA** : analyse des risques lies au systeme de prediction

6.2 AMDEC des machines industrielles MECHA

L'analyse du dataset (110 000 enregistrements) a permis d'identifier 5 modes de defaillance, classes par criticite :

Mode de defaillance	Frequence	Gravite	Detectabilite	Criticite (F x G x D)	Description
Surchauffe (Overheating)	4	5	3	60	Temperature superieure a 100 degres C, degradation progressive des composants mecaniques. Represente 35% des pannes observees.
Probleme de vibration (Vibration Issue)	4	4	3	48	Vibrations anormales dues a l'usure des roulements ou au desalignement. Represente 30% des pannes. 40% des pannes reelles sont liees aux roulements.
Chute de pression (Pressure Drop)	3	3	4	36	Perte de pression hydraulique ou pneumatique. Represente 20% des pannes.
Defaut electrique (Electrical Fault)	2	5	2	20	Court-circuit, surcharge, defaut d'isolation. Represente 15% des pannes. Gravite maximale car risque securite.
Usure d'outil (Tool Wear Failure)	3	2	4	24	Usure progressive de l'outil de coupe. Issu du dataset AI4I 2020.

Echelle de notation : Frequence (1=rare, 5=tres frequent), Gravite (1=negligeable, 5=catastrophique), Detectabilite (1=toujours detecte, 5=indetectable)


6.3 Analyse des indicateurs de detection

Pour chaque mode de defaillance, les capteurs et seuils de detection sont definis :

Mode de defaillance	Capteur principal	Seuil d'alerte	Seuil critique	Fenetre temporelle
Surchauffe	Temperature	Superieur a 90 degres C	Superieur a 100 degres C	Tendance sur 1h (temp_trend_1h)
Vibration	Vibration	Superieur a 50 mm/s	Superieur a 70 mm/s	Moyenne mobile 10 min (vibr_rolling_10min)
Chute de pression	Pression	Inferieur a 2.5 bar	Inferieur a 2.0 bar	Instantane
Defaut electrique	Energie	Superieur a 5 kW	Superieur a 7 kW	Ratio energie/vibration
Usure d'outil	Tool wear	Superieur a 180 min	Superieur a 220 min	Cumulatif

6.4 Matrice de criticite

Matrice de Criticite AMDEC



Matrice de Criticite AMDEC

6.5 Actions de mitigation par l'IA

Mode de defaillance	Action IA	Modele utilise	Gain attendu
Surchauffe	Alerte predictive 24-48h avant, recommandation arret preventif	Random Forest + RUL	Reduction de 60% des arrêts pour surchauffe
Vibration	Detection precoce de desalignement, planification remplacement roulements	Isolation Forest + RF	Reduction de 40% des pannes de roulement
Chute de pression	Detection de fuite progressive	Isolation Forest	Detection 2h avant arret
Defaut electrique	Identification de surcharge anormale	Isolation Forest	Prevention des courts-circuits
Usure d'outil	Estimation du temps restant avant remplacement	RF Regressor RUL	Optimisation du stock de pieces

6.6 AMDEC du systeme IA

Mode de defaillance IA	Frequence	Gravite	Criticite	Mitigation
Faux negatif (panne non detectee)	3	5	15	Seuil de prediction abaisse a 0.3 (vs 0.5), double validation par Isolation Forest
Faux positif (fausse alerte)	2	2	4	Precision de 98.8%, validation Human-in-the-Loop
Derive du modele (concept drift)	3	4	12	Monitoring F1 en production, reentrainement trimestriel
Donnees manquantes (capteur defaillant)	3	3	9	Imputation par mediane, mode fallback heuristique
Indisponibilite API	2	4	8	Health check toutes les 10s, redemarrage automatique Docker
Biais de profil machine	2	3	6	Entrainement avec class_weight balanced, 4 profils representes

6.7 Impact de l'IA sur la criticite des defaillances

Mode de defaillance	Criticite SANS IA	Criticite AVEC IA	Reduction
Surchauffe	60	24	-60%
Vibration	48	24	-50%
Chute de pression	36	18	-50%
Defaut electrique	20	12	-40%
Usure d'outil	24	8	-67%

L'introduction de la maintenance predictive par IA reduit la criticite globale de 50% en moyenne, principalement grace a l'amelioration de la detectabilite (passage de detection reactive a detection predictive).

7. Solution applicative integree (C4)

7.1 API REST — FastAPI

L'API constitue le coeur de la solution applicative. Elle expose 9 endpoints REST :

Methode	Route	Description	Modele ML
GET	/health	Health check (etat modeles, uptime)	—
POST	/predict	Prediction maintenance unitaire	Random Forest (fallback: XGBoost)
POST	/predict/batch	Prediction batch (max 100 machines)	Random Forest
POST	/predict/rul	Estimation RUL (heures restantes)	RF Regressor
POST	/anomaly	Detection d'anomalies	Isolation Forest
GET	/metrics	Metriques performance et statistiques API	—
GET	/model-info	Model Cards (EU AI Act)	—
GET	/alerts/config	Lecture des seuils d'alerte	—
PUT	/alerts/config	Modification des seuils d'alerte	—

Caracteristiques techniques :

- 1 157 lignes de code
- 10 schemas Pydantic pour la validation des entrees/sorties
- Chaine de fallback : Random Forest, puis XGBoost, puis heuristique mock
- Categorisation automatique du risque : low, medium, high, critical
- Categorisation RUL : urgent (inferieur a 24h), soon (inferieur a 72h), moderate (inferieur a 168h), safe
- Authentification par cle API (header X-API-Key)
- CORS configurable
- Documentation Swagger auto-generee

7.2 Dashboard Streamlit — 5 vues metier


Le dashboard Streamlit (918 lignes, 34 675 octets) offre 5 vues adaptees aux differents profils utilisateurs :

Vue 1 — Groupe (Direction Generale)

KPIs consolides des 5 usines : TRS global, taux de maintenance, taux d'anomalies, nombre de machines actives, RUL moyen. Comparaison inter-sites et repartition des pannes par usine.

Vue 2 — Site (Directeur d'Usine)

Vue operationnelle par usine avec filtrage par site. KPIs du site, etat de chaque machine (profil, temperature, vibration, RUL, risque), alertes actives en temps reel.



Vue Site Streamlit

Vue 3 — Machine (Equipe Maintenance)


Diagnostic individuel d'une machine. Capteurs en temps reel (temperature, vibration, RUL sur 3 jours), jauge de score de risque d'arret (0-100%), facteurs de risque normalises.



Vue Machine Streamlit

Vue 4 — Alertes (Tous niveaux)


Centre d'alertes avec filtres par usine, type et severite. Compteurs : alertes critiques, alertes majeures, total. Tableau detaille avec horodatage, machine, type, niveau et detail.



Centre d'Alertes Streamlit

Vue 5 — Modele IA (Data Team)

Comparaison des 5 modeles ML, distribution de la variable cible, correlation des features avec maintenance_required, distribution par profil de machine. Conformite EU AI Act affichee.




Performance Modele IA Streamlit

7.3 Dashboards Grafana — 3 tableaux de bord par role

Grafana, retenu en MSPR 1 comme outil de restitution principal, fournit 3 dashboards adaptes aux differents niveaux hierarchiques :

Dashboard DG Groupe — Direction Generale

6 KPIs en temps reel (TRS global 96.9%, Taux Maintenance 3.10%, Taux Anomalies 8.60%, Machines Actives 100, Usines 5, RUL Moyen 348 min), benchmark des 5 usines, repartition des pannes et maintenance par usine.



Dashboard Grafana DG Groupe

Dashboard Directeur d'Usine


Filtrable par usine (variable Grafana). 4 KPIs du site (Machines Actives 21, Taux Maintenance Site 2.30%, Temperature Moyenne 66.5 degrees C, RUL Moyen Site 357 min). 3 jauges capteurs (Temperature, Vibration, Risque d'Arret) avec code couleur vert-jaune-rouge. Detail des machines avec tableau interactif. Pannes du site par type.



Dashboard Grafana Directeur Usine

Dashboard Technicien Maintenance

4 indicateurs d'alerte (Machines a Risque 0, RUL Critique 0, Surchauffe 0, Maintenance Requise 2). Plan d'action maintenance avec les machines critiques classees par priorite et action recommandee. Historique des pannes par type et par profil machine.



Dashboard Grafana Technicien

7.4 Regles metier implementees

Regle	Seuil	Action declenchee
Temperature critique	Superieur a 100 degres C	Alerte critique, recommandation arret
Vibration critique	Superieur a 70 mm/s	Alerte critique, verification roulements
RUL critique	Inferieur a 50 min	Alerte critique, maintenance urgente
TRS minimum	Inferieur a 75%	Alerte production
Taux de rebuts	Superieur a 3%	Alerte qualite
Taux d'anomalies	Superieur a 10%	Investigation data team
Human-in-the-Loop	Toute prediction	Validation humaine obligatoire avant action

8. Tests et validation (C5)

8.1 Strategie de test — Pyramide

Niveau	Nombre de tests	Couverture cible	Frequence
Tests unitaires	100+	Superieur ou egal a 80% du code	A chaque commit
Tests d'integration	20-30	Flux critiques	A chaque Pull Request
Tests de recette	5-10 scenarios	Cas metier	Avant release
Tests de performance	3-5 tests	Charge et stress	Hebdomadaire

8.2 Tests implementes

Tests de qualite des donnees (test_data_quality.py — 14 tests)

- Structure du dataset : non vide, minimum 50 000 lignes, colonnes obligatoires presentes, colonnes enrichies presentes
- Qualite des donnees : pas de valeurs nulles sur les colonnes critiques, plages de valeurs respectees (temperature entre -10 et 200, vibration positive, RUL positive)
- Coherence metier : 50 a 100 machines, 5 usines, noms d'usines corrects, minimum 10 machines par usine, variable cible binaire, test anti-leakage machine_status, downtime_risk entre 0 et 1

Tests des modeles ML (test_model.py — 12 tests)

- Random Forest : chargement, prediction, prediction binaire, predict_proba, nombre de features
- XGBoost : chargement, prediction, prediction binaire
- Isolation Forest : chargement, prediction, sortie dans {-1, 1}
- RF Regressor RUL : chargement, prediction positive (11 features), prediction numerique

Tests d'integration (test_integration.py — 6 tests)

- Machine normale non detectee comme critique
- Machine critique correctement detectee avec alertes
- Coherence batch vs unitaire
- Detection d'anomalies sur valeurs critiques
- RUL normal superieur a RUL critique
- Workflow complet : /health, /predict, /anomaly, /predict/rul, /metrics, /model-info

8.3 Donnees de test

Jeu	Temperature	Vibration	RUL	Risque	Attendu
SAMPLE_NORMAL	75 degres C	35 mm/s	400 min	0.1	Pas d'alerte
SAMPLE_CRITICAL	115 degres C	85 mm/s	10 min	0.95	Alerte critique

8.4 Seuils d'acceptation

Metrique	Seuil minimum	Seuil cible
Accuracy	85% ou plus	90% ou plus
Precision	85% ou plus	90% ou plus
Recall	90% ou plus	95% ou plus
F1-Score	87% ou plus	92% ou plus
MAE (RUL)	Inferieur ou egal a 24h	Inferieur ou egal a 12h
R-carre (RUL)	0.80 ou plus	0.90 ou plus


8.5 Scenarios de recette metier

Ref.	Scenario	Critere de reussite
REC-01	Detection anomalie vibration	Alerte declenchee en moins de 2 min
REC-02	Prediction panne a 48h	Estimation RUL entre 24 et 72h
REC-03	Pas de fausse alerte en conditions normales	Zero alerte sur machine saine
REC-04	Donnees capteur manquantes	Systeme degrade sans crash
REC-05	Mise a jour modele sans regression	F1 stable a plus ou moins 5%

9. Integration continue (C6)

9.1 Pipeline GitHub Actions

La pipeline CI/CD est implementee dans `.github/workflows/ci.yml` (146 lignes) et s'execute a chaque push ou Pull Request sur la branche main :



Pipeline CI/CD GitHub Actions

9.2 Detail des 3 jobs

Job 1 — Lint (Ruff)

- Environnement : Ubuntu, Python 3.11
- Commandes : `ruff check` (verification regles de style), `ruff format --check` (verification formatage)
- Bloquant : le job suivant ne demarre pas si le lint echoue

Job 2 — Tests (pytest)

- Prerequis : service PostgreSQL 15-alpine lance pour les tests d'integration
- Commandes : `pytest` avec couverture (`--cov=api --cov=models`)
- Rapports generes : XML (machine-readable) + HTML (human-readable)
- Artefact uploadé : rapport de couverture conserve 14 jours
- Cache pip active pour acclereler l'installation

Job 3 — Build Docker

- Strategie matrix : construction parallele des images `api` et `dashboard`
 - Docker Buildx avec cache GitHub Actions (GHA)
 - Verification : `docker inspect` pour valider l'image
 - Pas de push (build + validation uniquement)
-

10. Documentation et conformite (C7)

10.1 Inventaire des documents

9 documents techniques totalisant plus de 180 Ko de documentation :

Document	Taille	Competence couverte	Contenu
architecture.md	18.5 Ko	C2	Architecture 7 couches, comparatifs, dimensionnement
technical_choices.md	24.3 Ko	C2	Justification de chaque choix technique
validation_plan.md	27.9 Ko	C5	Pyramide de tests, scenarios de recette, matrice de tracabilite
deployment_plan.md	23.4 Ko	C3/C4	Plan 4 phases sur 12 mois, criteres Go/No-Go
change_management.md	23.0 Ko	C8	4 axes, FutureWheel, Modele de Bridge
rgpd_analysis.md	21.6 Ko	C7	Analyse RGPD, EU AI Act, PIA
client_interview.md	20.6 Ko	C1	Entretien semi-directif, 24 questions, verbatims
user_guide.md	10.8 Ko	C7	Guide utilisateur metier (interpretation resultats, limites)
soutenance.md	10.7 Ko	—	Support de soutenance (15 slides)

10.2 Guide utilisateur metier

Le guide utilisateur (user_guide.md) est un document synthetique de 1 a 2 pages destine aux equipes maintenance. Il couvre :

- Ce que fait la solution (detection predictive, estimation RUL, alertes)
- Comment interpreter les resultats (niveaux de risque, categories RUL)
- Les limites et conditions d'utilisation (donnees synthetiques, Human-in-the-Loop obligatoire)
- Les actions a entreprendre selon le niveau d'alerte

10.3 Conformite entre realisation et cahier des charges

Exigence du sujet MSPR 2	Fichier/composant correspondant	Statut
Code source versionne sur Git	Repository GitHub HASHT85/MSPR2-MECHA	Conforme
Jeux de donnees + hypotheses	data/processed/ + data_dictionary.md	Conforme
Modeles ML avec metriques	models/saved_models/ + models/evaluation/	Conforme
Deploiement Docker	docker-compose.yml + 2 Dockerfiles	Conforme
CI/CD	.github/workflows/ci.yml	Conforme
Solution applicative	API + Streamlit + Grafana	Conforme
Schema d'architecture	docs/architecture.md	Conforme
Choix techniques argumentes	docs/technical_choices.md	Conforme
RGPD	docs/rgpd_analysis.md	Conforme
Compte-rendu client	docs/client_interview.md	Conforme
Guide utilisateur	docs/user_guide.md	Conforme
Conduite du changement	docs/change_management.md	Conforme
Plan de validation	docs/validation_plan.md	Conforme

11. Conduite du changement (C8)

11.1 Populations impactees

Population	Effectif	Niveau de changement
Operateurs machines	Environ 80 personnes	Modere
Techniciens maintenance	Environ 30 personnes	Fort
Responsables maintenance	5 personnes	Fort
Direction industrielle	3 a 5 personnes	Faible
Equipe IT/DSI	5 a 10 personnes	Fort

11.2 Les 4 axes de la conduite du changement

Axe 1 — Informer

- Note de direction officielle (Semaine 1)
- Kick-off projet (Semaine 2)
- Video de presentation (3 min) : "Ce que l'IA fait et ne fait pas"
- FAQ initiale (Semaine 3)
- Messages adaptes par population (direction, techniciens, operateurs)

Axe 2 — Communiquer

- COPIL mensuel (direction + responsables)
- COPROJ bi-mensuel (equipe projet + DSI)
- Points usine hebdomadaires (responsable site + ambassadeurs)
- Newsletter "MECHA Predict News" mensuelle
- Gestion proactive des rumeurs (4 reponses types preparees)

Axe 3 — Former

Programmes de formation adaptes a chaque profil :

Profil	Duree	Format	Contenu
Operateurs	1h	Presentiel usine	Lire le dashboard, comprendre les alertes
Techniciens	4h (2 x 2h)	Presentiel + e-learning	Interpreter les predictions, agir sur les alertes
Responsables	4h (2 x 2h)	Presentiel	Piloter avec les KPIs, valider les decisions IA
Direction	1h	Visioconference	Vision strategique, ROI
IT/DSI	8h (2 jours)	Presentiel + TP	Administration, maintenance, troubleshooting

Supports de formation :

- 5 tutoriels video (2 a 5 min chacun)
- Fiches reflexes plastifiees A5
- E-learning avec quiz (seuil de validation : 80% ou plus)
- Sandbox de test

Axe 4 — Faire participer

- 1 a 2 ambassadeurs par site (5 au total)
- 4 ateliers de co-construction
- Feedback continu : bouton in-app, boite a idees, enquetes
- Retour d'experience (REX) a chaque fin de phase

11.3 Modeles de reference

FutureWheel : Methode de cartographie des impacts en cercles concentriques, des effets directs (cercle 1 : alertes predictives, modification des routines) aux effets indirects (cercle 2 : reduction des couts, montee en competences) jusqu'aux effets lointains (cercle 3 : culture data-driven, competitivite renforcee).

Modele transitionnel de William Bridge : 3 phases de transition psychologique :

1. Fin de l'ancien monde : abandon de la maintenance curative pure
2. Zone neutre : cohabitation ancien/nouveau systeme, periode d'adaptation
3. Nouveau depart : adoption du systeme predictif, nouveaux reflexes

11.4 KPIs de suivi du changement

Categorie	Indicateur	Objectif
Adoption	Taux de connexion au dashboard	60% puis 90%
Adoption	Formation completee	100%
Adoption	Alertes consultees dans les 15 min	70% puis 95%
Satisfaction	NPS utilisateurs	Superieur ou egal a 7 sur 10
Impact metier	Arrets non planifies par mois	De 15 a 5 ou moins (-66%)
Impact metier	Cout maintenance	-20%
Impact metier	Disponibilite machines	De 88% a 95% ou plus
Impact metier	Delai de reaction	De 4h a 1h

12. Conformance réglementaire — RGPD et EU AI Act

12.1 Cadre réglementaire

Texte	Applicabilité
RGPD (UE 2016/679)	Données personnelles des opérateurs (emails, logs)
Loi Informatique et Libertés	Sites français (Lyon, Toulouse, Nantes)
LOPDGDD	Sites espagnols (Barcelone, Madrid)
EU AI Act	Système de décision assisté par IA
Directive NIS 2	Sécurité des réseaux et systèmes d'information
IEC 62443	Sécurité des systèmes industriels

12.2 Classification des données

Données machine (non personnelles) : température, vibration, pression, humidité, énergie, identifiant machine, historique maintenance, prédictions IA, alertes. Conservation : 2 ans.

Données personnelles minimales : adresses email des responsables maintenance, adresses IP dans les logs, identifiants de connexion. Conservation : 6 mois à 1 an.

12.3 Analyse d'impact (PIA)

- **Configuration actuelle** (données machine uniquement) : PIA non nécessaire
- **Configuration avec données opérateurs** (évolution future, environ 80 opérateurs) : PIA obligatoire

Risques identifiés dans le scénario avec données opérateurs :

Risque	Niveau
Surveillance perçue des opérateurs	Critique
Discrimination basée sur corrélations IA	Critique
Utilisation des données pour sanctions	Critique
Accès non autorisé	Significatif
Profilage involontaire	Significatif

12.4 Classification EU AI Act

Le système MECHA Predict est classé en **risque limité** selon le règlement européen sur l'intelligence artificielle. Les obligations de transparence sont respectées :

Obligation	Implementation
Documentation du modele	Model Cards pour les 5 modeles
Donnees d'entrainement documentees	Dictionnaire de donnees, hypotheses, limites
Limites et biais documentes	4 types de biais identifies par modele
Human-in-the-Loop	Mention explicite dans le dashboard et l'API : toute prediction doit etre validee par un operateur qualifie
Transparence	L'IA fournit des recommandations, pas des decisions


12.5 Mesures techniques de securite

- Chiffrement TLS 1.3 (donnees en transit), AES-256 (donnees au repos)
- Controle d'accès RBAC avec 6 roles definis
- Authentification API par cle (header X-API-Key)
- Journalisation des acces
- Variables sensibles dans .env (hors du code source)
- .env dans .gitignore, .env.example fourni

13. Plan de déploiement multi-sites

13.1 Architecture de déploiement centralisée

L'architecture retenue est centralisée, avec un serveur principal a Lyon (siege) et des passerelles edge par site :



Architecture de déploiement centralisée

13.2 Déploiement progressif en 4 phases

Phase	Periode	Sites	Machines	Objectif
Phase 1 — Pilote	Juin-Aout 2026	Lyon	10	Valider en conditions reelles
Phase 2 — France	Sept-Nov 2026	Toulouse + Nantes	30 (cumul)	Deployer les sites francais
Phase 3 — Espagne	Dec 2026-Fev 2027	Barcelone + Madrid	50 (cumul)	Adaptation i18n, extension
Phase 4 — Stabilisation	Fev-Mai 2027	Tous	50	Optimisation, formation continue

13.3 Criteres Go/No-Go par phase

Critere	Poids	Seuil minimum
Infrastructure operationnelle	20%	100%
Donnees capteurs disponibles	20%	95% ou plus
Accuracy modele	20%	80% ou plus
Fausses alertes	15%	15% ou moins
Adoption utilisateurs	15%	60% ou plus
Satisfaction utilisateurs	10%	6 sur 10 ou plus

13.4 Plan de rollback

Criteres de declenchement du retour arriere :

- Perte de donnees superieure a 30% pendant plus d'1 heure
- Plus de 5 fausses alertes critiques en 24 heures
- Indisponibilite API superieure a 2 heures
- Impact negatif mesurable sur la production
- Rejet par plus de 50% des utilisateurs

13.5 Regles de notification

Severite	Canaux	Delai
Information	Dashboard uniquement	1 heure
Avertissement	Email + Dashboard	15 minutes
Critique	SMS + Email + Dashboard	5 minutes

14. Bilan et perspectives

14.1 Bilan quantitatif du projet

Metrique	Valeur
Lignes de code total	Environ 4 630 lignes
Fichiers du projet	Environ 75 fichiers
Taille du dataset	110 000 enregistrements, 30 colonnes
Modeles ML entraines	5 modeles
Endpoints API	9 routes REST
Vues Streamlit	5 pages metier
Dashboards Grafana	3 par role
Tests automatises	38+ tests (14 donnees + 12 modeles + 6 integration + tests API)
Documents techniques	9 documents, 180+ Ko
Services Docker	4 conteneurs
Pipeline CI/CD	3 jobs (lint, test, build)
Competences couvertes	8 sur 8 (C1 a C8)

14.2 Couverture des competences

Competece	Description	Preuve
C1	Collecter les besoins metiers	client_interview.md — Entretien 2h30, 24 questions, 10 besoins fonctionnels
C2	Concevoir une architecture applicative	architecture.md + technical_choices.md — 7 couches, 10 comparatifs
C3	Developper une application	API FastAPI (1 157 lignes) + Dashboard Streamlit (918 lignes) + Pipeline ML (887 lignes)
C4	Developper une solution integree	9 endpoints API + 5 vues Streamlit + 3 dashboards Grafana + regles metier
C5	Effectuer les tests	validation_plan.md + 38 tests implements + 5 scenarios de recette
C6	Appliquer l'integration continue	.github/workflows/ci.yml — 3 jobs sequentiels
C7	Verifier conformite et documenter	9 documents + guide utilisateur + conformite cahier des charges
C8	Conduire le changement	change_management.md — 4 axes, FutureWheel, Bridge, KPIs

14.3 Limites identifiees

Limite	Impact	Plan de remediation
Donnees synthetiques	Performances reelles peuvent differer	Reevaluation avec donnees de production
Recall a 62%	38% des pannes non detectees	Optimisation du seuil, enrichissement features
R-carre RUL a 59.8%	Precision limitee de l'estimation du temps avant panne	Ajout de features temporelles, modele LSTM
Pas de deep learning	Potentiellement moins performant sur les sequences longues	LSTM prevu si donnees suffisantes (plus de 2 ans d'historique)
Base centralisee	Point unique de defaillance	Backup quotidien, buffer local par site
Streamlit = prototype	Interface moins professionnelle qu'une application custom	Suffisant pour la V1, refonte React possible en V2

14.4 Perspectives d'evolution

Horizon	Evolution	Condition de declenchement
Court terme (6 mois)	TimescaleDB pour series temporelles	Volume superieur a 10 Go par mois
Court terme (6 mois)	Redis pour cache des predictions	Latence API superieure a 500 ms
Moyen terme (12 mois)	MLflow pour versioning des modeles	Plus de 3 modeles en production
Moyen terme (12 mois)	Apache Kafka pour streaming	Plus de 100 machines
Long terme (18+ mois)	LSTM / Transformer pour deep learning	Plus de 2 ans d'historique, plus de 100 machines
Long terme (18+ mois)	Kubernetes pour orchestration	Plus de 10 sites ou microservices

14.5 ROI projete

Poste	Estimation annuelle
Reduction des arrêts non planifiés (-25%)	150 000 a 250 000 euros
Optimisation du stock de pieces (-30%)	30 000 a 60 000 euros
Reduction des penalites contractuelles	50 000 a 100 000 euros
Reduction de la consommation energetique	20 000 a 40 000 euros
Total economies	200 000 a 300 000 euros par an
Investissement initial	150 000 euros
Retour sur investissement	Inferieur a 12 mois

15. Annexes

15.1 Inventaire complet des fichiers

Composant	Fichiers	Volume
API FastAPI	api/main.py, api/Dockerfile	1 157 lignes
Dashboard Streamlit	app/src/dashboard.py, app/Dockerfile	918 lignes
Scripts data	generate_data.py, merge_datasets.py	931 lignes
Pipeline ML	train_models.py	887 lignes
Schema BDD	db/init.sql, db/load_data.sh	123 lignes
Tests	3 fichiers (data, modeles, integration)	432 lignes
CI/CD	.github/workflows/ci.yml	146 lignes
Docker	docker-compose.yml	159 lignes
Documentation	9 fichiers	180+ Ko
Grafana	3 dashboards JSON + 2 provisioning	5 fichiers
Modeles	5 .joblib + 5 model cards + 6 metriques	21 fichiers

15.2 Stack technique complete

Couche	Technologies
Langage	Python 3.11
ML	scikit-learn, XGBoost, pandas, NumPy, joblib
API	FastAPI, Pydantic, uvicorn
Dashboard	Streamlit, Plotly, requests
Monitoring	Grafana OSS
BDD	PostgreSQL 16 Alpine
Conteneurisation	Docker, Docker Compose
CI/CD	GitHub Actions, Ruff, pytest, pytest-cov
Versionning	Git, GitHub

15.3 Captures d'ecran

Tendance de temperature par machine sur 3 jours, avec seuil critique a 100 degrees C :



Tendance Temperature par Machine

15.4 References bibliographiques

- EU AI Act — Reglement (UE) 2024/1689 du Parlement europeen
- RGPD — Reglement (UE) 2016/679 du Parlement europeen
- EN 9100 — Systemes de management de la qualite aeronautique
- IATF 16949 — Systemes de management de la qualite automobile
- IEC 62443 — Securite des systemes d'automatisation industrielle
- Directive NIS 2 (UE) 2022/2555 — Securite des reseaux et systemes d'information
- scikit-learn Documentation — <https://scikit-learn.org>
- XGBoost Documentation — <https://xgboost.readthedocs.io>
- AI4I 2020 Predictive Maintenance Dataset — UCI Machine Learning Repository

Document valide par : Equipe projet MECHA

Date de validation : Mai 2026

Repository : <https://github.com/HASHT85/MSPR2-MECHA>