EPSI • RNCP35584 NIVEAU 7 • BLOC 4 — MSPR TPRE841 (LIVRABLE 04 — PIPELINE DATA & SQL)

Dictionnaire de Données — MECHA Dataset Hybride (MSPR 2 — TPRE841)

Version : 3.1 | **Date** : Mai 2026 | **Auteur** : Équipe MECHA • **Sources** : Dataset MECHA simulé (100 000 lignes) + Jeu public communautaire de référence AI4I 2020 Predictive Maintenance (10 000 lignes, UCI ML Repository / Kaggle — aucune donnée industrielle confidentielle privée conformément au cahier des charges p.4)

1. Vue d'ensemble

Propriété	Valeur
Nombre d'enregistrements	**110 000** (100 000 simulés + 10 000 publics AI4I 2020)
Nombre de colonnes	**30**
Machines couvertes	**100 identifiants** (IDs 1–50 parc simulé MECHA + IDs 51–100 benchmark public AI4I)
Usines MECHA	**5 sites** (3 en France : Lyon, Toulouse, Nantes ; 2 en Espagne : Barcelone, Madrid)
Granularité temporelle	1 mesure par minute et par machine
Taille fichier exploitable	~20 Mo (`data/processed/mecha_dataset_processed.csv`)
Taille fichier brut avant fusion	~16 Mo (`data/raw/mecha_dataset_raw.csv`) + `data/external/ai4i_2020_real.csv`

Composition par source de données

Source (`data_source`)	Enregistrements	Période	Nature et conformité
`MECHA_simulated`	100 000	Janvier 2025	Séries temporelles IoT simulées reproduisant la dégradation progressive de 50 machines sur 5 usines FR/ES
`AI4I_2020_real`	10 000	Mars 2025	Jeu de données public communautaire *AI4I 2020 Predictive Maintenance* (UCI Machine Learning Repository, licence CC BY 4.0) harmonisé au schéma MECHA

> **Conformité confidentialité industrielle (Cahier des charges Section III, p.4)** : Aucune donnée industrielle privée ou confidentielle n'est utilisée. Le corpus combine exclusivement une simulation métier Python reproductible (`seed=42`) et un jeu ouvert académique de référence (UCI / Kaggle).

2. Description exhaustive des 30 colonnes

2.1 Colonnes d'identification et de contexte industriel (9 colonnes)

#	Colonne	Type SQL / Python	Description	Valeurs / Plage	Origine
1	`timestamp`	`TIMESTAMP` / `datetime`	Horodatage synchronisé (UTC/NTP) de la mesure	Janvier – Mars 2025	Toutes sources
2	`machine_id`	`INTEGER` / `Int64`	Identifiant unique de l'équipement	`1` – `50` (MECHA simulé), `51` – `100` (AI4I public)	Toutes sources
3	`usine_id`	`VARCHAR(20)` / `str`	Code du site industriel MECHA	`USN-FR-01` à `USN-FR-03`, `USN-ES-01`, `USN-ES-02`	Enrichissement MSPR 2
4	`usine_nom`	`VARCHAR(50)` / `str`	Ville d'implantation de l'usine	`Lyon`, `Toulouse`, `Nantes`, `Barcelone`, `Madrid`	Enrichissement MSPR 2
5	`usine_pays`	`VARCHAR(20)` / `str`	Pays d'implantation	`France`, `Espagne`	Enrichissement MSPR 2
6	`ligne_production`	`VARCHAR(10)` / `str`	Ligne d'atelier automatisée (MES)	`LP-A`, `LP-B`, `LP-C`	Enrichissement MSPR 2
7	`type_piece`	`VARCHAR(50)` / `str`	Référence fonctionnelle usinée	`Arbre_moteur`, `Disque_frein`, `Carter_boite`, `Pale_turbine`, `Axe_roue`	Enrichissement MSPR 2
8	`machine_profile`	`VARCHAR(20)` / `str`	Profil structurel de fiabilité machine	`robuste`, `standard`, `fragile`, `vieillissante`	Toutes sources
9	`data_source`	`VARCHAR(30)` / `str`	Origine de l'enregistrement (traçabilité ETL)	`MECHA_simulated`, `AI4I_2020_real`	Traçabilité MSPR 2

2.2 Mesures brutes des capteurs IoT (5 colonnes — Features ML n°1 à 5)

#	Colonne	Type	Unité	Description	Plage nominale / observée	Rôle ML
10	`temperature`	`FLOAT`	°C	Température capteur broche / bâti machine	`25.0` – `125.0` °C	Feature ML #1 (corrélation forte)
11	`vibration`	`FLOAT`	mm/s	Vitesse vibratoire efficace (RMS)	`0.0` – `120.0` mm/s	Feature ML #2 (corrélation modérée)
12	`humidity`	`FLOAT`	%	Humidité relative ambiante atelier	`30.0` – `80.0` %	Feature ML #3 (bruit environnemental)
13	`pressure`	`FLOAT`	bar	Pression du circuit hydraulique / pneumatique	`0.5` – `5.0` bar	Feature ML #4

#	Colonne	Type	Unité	Description	Plage nominale / observée	Rôle ML
14	`energy_consumption`	`FLOAT`	kWh	Consommation énergétique instantanée	`0.3` – `7.0` kWh	Feature ML #5

2.3 Features temporelles dérivées (5 colonnes — Features ML n°6 à 10)

#	Colonne	Type	Fenêtre	Formule / Signification métier	Rôle ML
15	`temp_rolling_10min`	`FLOAT`	10 min	Moyenne glissante de `temperature` sur 10 mesures (lissage du bruit capteur)	Feature ML #6
16	`temp_trend_1h`	`FLOAT`	60 min	Pente linéaire de température sur 1h (détection d'emballement thermique)	Feature ML #7
17	`vibr_rolling_10min`	`FLOAT`	10 min	Moyenne glissante de `vibration` sur 10 mesures	Feature ML #8
18	`temp_std_30min`	`FLOAT`	30 min	Écart-type de `temperature` sur 30 min (instabilité thermique)	Feature ML #9
19	`energy_vibr_ratio`	`FLOAT`	Instantané	Ratio `energy_consumption / max(vibration, 0.1)` (rendement électromécanique)	Feature ML #10

2.4 Colonnes d'état machine, cibles ML et score métier (7 colonnes)

#	Colonne	Type	Valeurs / Plage	Usage et règles strictes anti-fuite (*Data Leakage*)
20	`machine_status`	`INTEGER`	`0` = Arrêt planifié, `1` = Production, `2` = Panne	Supervision SCADA/Grafana uniquement — **EXCLUE des features ML** (fuite directe de l'état de panne)
21	`anomaly_flag`	`INTEGER`	`0` = Normal, `1` = Anomalie seuil	Indicateur métier de pré-alerte capteur
22	`predicted_remaining_life`	`INTEGER`	`0` – `500` min	**Variable cible du modèle RUL** (`RandomForestRegressor`) — **EXCLUE des features de classification**
23	`failure_type`	`VARCHAR(30)`	`Normal`, `Overheating`, `Vibration_Issue`, `Pressure_Drop`, `Electrical_Fault`, `Tool_Wear_Failure`, `Random_Failure`	Typologie AMDEC de défaillance pour diagnostic
24	`maintenance_required`	`INTEGER`	`0` = Non (~95,3 %), `1` = Oui (~4,7 % en test)	**Variable cible principale de classification binaire**
25	`maintenance_type`	`VARCHAR(20)`	`none`, `preventive`, `corrective`, `recommended`	Catégorie d'intervention GMAO

#	Colonne	Type	Valeurs / Plage	Usage et règles strictes anti-fuite (*Data Leakage*)
26	`downtime_risk`	`FLOAT`	`0.0` – `1.0`	Score synthétique d'affichage `0.30*temp_risk + 0.25*vibr_risk + 0.45*rul_risk` — **EXCLU des features ML**

2.5 Colonnes complémentaires issues du benchmark public AI4I 2020 (4 colonnes)

#	Colonne	Type SQL / Pandas	Unité	Description	Plage observée	Disponibilité
27	`torque_nm`	`FLOAT` / `float64`	Nm	Couple mécanique broche	`3.8` – `76.6` Nm	Renseignée sur AI4I (`NULL` sur simulé)
28	`rotational_speed_rpm`	`INTEGER` / `Int64`	tr/min	Vitesse de rotation de broche	`1168` – `2886` rpm	Renseignée sur AI4I (`NULL` sur simulé)
29	`tool_wear_min`	`INTEGER` / `Int64`	min	Durée d'usure cumulée de l'outil coupant	`0` – `253` min	Renseignée sur AI4I (`NULL` sur simulé)
30	`product_quality`	`VARCHAR(5)` / `str`	—	Gamme de qualité pièce (`L` Low, `M` Medium, `H` High)	`L` , `M` , `H`	Renseignée sur AI4I (`NULL` sur simulé)

---

3. Référentiel des usines et profils machines

3.1 Répartition des 5 sites industriels MECHA

Code usine	Site	Pays	Parc simulé	Spécificité industrielle
`USN-FR-01`	MECHA Lyon	France	Machines 1 à 10 (10)	Site historique et pilote Industrie 4.0
`USN-FR-02`	MECHA Toulouse	France	Machines 11 à 20 (10)	Pôle aéronautique haute précision
`USN-FR-03`	MECHA Nantes	France	Machines 21 à 30 (10)	Usinage structures et sous-ensembles
`USN-ES-01`	MECHA Barcelone	Espagne	Machines 31 à 40 (10)	Grande série automobile
`USN-ES-02`	MECHA Madrid	Espagne	Machines 41 à 50 (10)	Site polyvalent récent

3.2 Profils d'hétérogénéité du parc machines

Profil	Machines concernées	Température nominale	Vibration nominale	Prob. panne	Description
`robuste`	1, 10, 20, 30, 40, 50 (6 machines)	70 °C	35 mm/s	2 %	Centres d'usinage récents
`standard`	32 machines	75 °C	40 mm/s	4 %	Cœur de flotte MECHA
`fragile`	3, 8, 15, 22, 32, 41, 48 (7 machines)	82 °C	50 mm/s	8 %	Machines fortement sollicitées

Profil	Machines concernées	Température nominale	Vibration nominale	Prob. panne	Description
`vieillissante`	5, 12, 24, 37, 43 (5 machines)	85 °C	55 mm/s	10 %	Équipements anciens sous surveillance renforcée

3.3 Harmonisation des modes de défaillance AI4I 2020 vers MECHA

Code AI4I 2020	Libellé harmonisé MECHA	Phénomène physique
`TWF` (*Tool Wear Failure*)	`Tool_Wear_Failure`	Usure critique de l'outil de coupe (200–240 min)
`HDF` (*Heat Dissipation Failure*)	`Overheating`	Défaut de dissipation thermique
`PWF` (*Power Failure*)	`Electrical_Fault`	Puissance mécanique hors plage nominale
`OSF` (*Overstrain Failure*)	`Vibration_Issue`	Surcharge couple × usure générant des vibrations
`RNF` (*Random Failure*)	`Random_Failure`	Défaillance stochastique non anticipable (~0,1 %)

---

4. Hypothèses de simulation et limites connues

4.1 Hypothèses métier retenues (`generate_data.py` & `merge_datasets.py`)

1. **Plage de production** : fonctionnement nominal de 06h00 à 22h00 et arrêt planifié nocturne (`machine_status = 0`).
2. **Dégradation continue** : accumulation progressive d'usure en fonctionnement, amplifiée par le profil de fragilité machine, entraînant une hausse corrélée de la température (+40 °C max) et de la vibration (+30 mm/s max) avec bruit gaussien capteur.
3. **Interventions** : remise à zéro de la dégradation après maintenance corrective (30–120 min) ou préventive.
4. **Conversion physique AI4I** : conversion des températures Kelvin en degrés Celsius (`T_°C = T_K - 273.15`) et typage strict en entiers nullables (`Int64`) des colonnes `rotational_speed_rpm` et `tool_wear_min` pour garantir l'import transactionnel PostgreSQL `\COPY` .

4.2 Limites documentées

- **Écart de domaine simulé vs AI4I public** : pour entraîner un modèle unique sur les deux sources sans valeurs manquantes, seules les **10 features capteurs communes** sont utilisées. Or dans AI4I 2020, les pannes `TWF` / `OSF` / `PWF` dépendent fortement de `torque_nm` et `tool_wear_min` (absents de la simulation), ce qui explique la performance plus basse observée isolément sur le sous-ensemble AI4I (`F1 ≈ 0,07`) contre `F1 ≈ 0,82–0,83` sur le parc simulé MECHA.
- **Déséquilibre des classes** (~95–97 % de mesures normales contre ~3–5 % nécessitant maintenance), traité par `class_weight='balanced'` et `scale_pos_weight` .
- **Absence volontaire de données personnelles** : aucun identifiant opérateur nominatif n'est présent (conformité RGPD *Privacy by Design*).