EPSI • RNCP35584 NIVEAU 7 • BLOC 4 — MSPR TPRE841 (LIVRABLE 05 — COMPETENCE C3 & C7)

Fiches Modeles Machine Learning (Model Cards — Conformite EU AI Act)

Projet : MECHA Predict — 5 modeles entraines sur 110 000 enregistrements (10 features capteurs sans fuite) •
Auteurs : Malek El Fayedh, Thibaut Doreau, Vincent Goncalves, Pierre-Louis Guinel

Fiche Modele 1/5 — Model Card : Random Forest Classifier

Informations Generales

Champ	Valeur
Nom du modele	Random Forest Classifier
Version	1.0.0
Date de creation	2026-05-30
Framework	scikit-learn
Type	Classification binaire
Statut	Modele principal (prioritaire)
Projet	MECHA - MSPR 2, Bloc 4, EPSI RNCP35584

Description

Modele de classification binaire base sur un ensemble d'arbres de decision (Random Forest) pour la prediction de la necessite de maintenance sur les machines de production MECHA. Ce modele est le **modele principal** selectionne lors de la MSPR 1 (F1=71%) et optimise dans cette iteration.

Objectif

Predire si une machine necessite une intervention de maintenance (`maintenance_required = 1`) a partir des donnees capteurs IoT en temps reel, afin de planifier les interventions avant les pannes.

Cas d'Usage Prevu

Utilisation principale

- **Maintenance predictive** : Detection proactive des besoins de maintenance sur 5 usines MECHA (aeronautique/automobile)
- **Planification** : Aide a la decision pour les equipes de maintenance
- **Reduction des arrets** : Minimiser les arrets non planifies en anticipant les defaillances

Utilisateurs cibles

- Responsables de maintenance des usines MECHA
- Ingenieurs de production
- Systemes automatises de planification de maintenance

Hors perimetre

- Ce modele ne remplace PAS le jugement humain

- Ne doit PAS etre utilise comme seul critere de decision pour des pieces critiques aeronautiques
- N'est PAS prevu pour des machines hors du parc MECHA

Donnees d'Entrainement

Source

- **Dataset** : `mecha_dataset_processed.csv` (100 000 mesures simulées MECHA + 10 000 mesures du jeu public communautaire UCI AI4I 2020)
- **Volume** : 110 000 lignes de mesures capteurs IoT (88 000 train / 22 000 test)
- **Periode** : Donnees temporelles (Janvier - Mars 2025)
- **Usines** : 5 sites de production MECHA (3 en France : Lyon, Toulouse, Nantes ; 2 en Espagne : Barcelone, Madrid)

Split des donnees

- **Methode** : Split temporel 80/20 (PAS aleatoire)
- **Train** : 80% premiers echantillons chronologiquement
- **Test** : 20% derniers echantillons chronologiquement
- **Par source** : le split est fait separement pour chaque source (MECHA simule, AI4I reel), sinon toutes les donnees reelles tombent dans le test
- **Justification** : Eviter le data leakage temporel ; on entraine sur le passe, on teste sur le futur

Features utilisees (10, capteurs uniquement)

Feature	Description	Type
`temperature`	Temperature machine (degres C)	Numerique
`vibration`	Niveau de vibration (mm/s)	Numerique
`humidity`	Taux d'humidite (%)	Numerique
`pressure`	Pression (bar)	Numerique
`energy_consumption`	Consommation energetique (kWh)	Numerique
`temp_rolling_10min`	Moyenne glissante temperature 10min	Numerique
`temp_trend_1h`	Tendance temperature 1h	Numerique
`vibr_rolling_10min`	Moyenne glissante vibration 10min	Numerique
`temp_std_30min`	Ecart-type temperature 30min	Numerique
`energy_vibr_ratio`	Ratio energie/vibration	Numerique

Features EXCLUES (data leakage)

Feature exclue	Raison
`machine_status`	**DATA LEAKAGE** confirme en MSPR 1 : cette variable encode directement l'etat de la machine et fuit l'information cible
`predicted_remaining_life`	**DATA LEAKAGE** identifie en revue MSPR 2 : dans la simulation, RUL = 500 x (1 - degradation) et la cible vaut 1 des que degradation > 0.6 ; la regle « RUL < 200 » reproduit la cible a 99 %
`downtime_risk`	**DATA LEAKAGE** : score composite construit a 45 % a partir du RUL

Desequilibre des classes

Classe	Proportion
0 (pas de maintenance)	~96.9%
1 (maintenance requise)	~3.1%

Gestion : `class_weight='balanced'` -- ajuste automatiquement les poids inversement proportionnels a la frequence des classes.

Hyperparametres

Parametre	Valeur	Justification
`n_estimators`	200	Bon compromis performance/temps
`max_depth`	15	Limiter le surapprentissage
`min_samples_split`	10	Regularisation
`min_samples_leaf`	5	Regularisation
`class_weight`	balanced	Gestion du desequilibre 96.9/3.1
`max_features`	sqrt	Standard pour la classification
`random_state`	42	Reproductibilite
`n_jobs`	-1	Parallelisation maximale

Metriques de Performance

> Les metriques exactes sont generees automatiquement lors de l'entrainement et sauvegardees dans `models/evaluation/results/random_forest_metrics.json` .

Metrique	Valeur sur jeu de test (n = 22 000)	Description
Accuracy	**97.93 %**	Taux global de predictions correctes
Precision	**72.71 %**	Proportion d'alertes declenchees reellement justifiees
Recall	**89.99 %**	Proportion de maintenances reelles detectees (93.3 % sur MECHA simule)
F1-Score	**80.43 %**	Moyenne harmonique precision/recall (82.2 % sur MECHA simule ; 7.3 % sur AI4I public hors couple/usure)
AUC-ROC	**98.80 %**	Capacite globale de discrimination du modele

Metrique principale : F1-Score

Le F1-Score est la metrique principale car : - L'accuracy seule est trompeuse avec 96.9% de classe majoritaire (un modele naif atteint 96.9% en predisant toujours 0) - Le recall est critique (ne pas manquer une maintenance = securite) - La precision est importante (eviter les faux positifs = couts d'arret inutiles)

Limites et Risques

Limites connues

1. **Desequilibre extreme** : Avec 3.1% de positifs, le modele peut avoir du mal a detecter tous les cas de maintenance
2. **Donnees synthetiques** : Le dataset est issu de simulations, les performances en production reelle peuvent differer
3. **Derive temporelle** : Les performances peuvent se degrader si les conditions d'exploitation changent (concept drift)
4. **Generalisation** : Entraine sur des machines MECHA specifiques, peut ne pas generaliser a d'autres types de machines

Risques

- **Faux negatifs** : Ne pas detecter une maintenance necessaire peut entrainer une panne
- **Faux positifs** : Declencher une maintenance inutile engendre des couts
- **Surapprentissage** : Malgre la regularisation, risque de surapprentissage sur les patterns specifiques du dataset

Biais Potentiels

Type de biais	Description	Mitigation
Biais temporel	Le modele peut apprendre des patterns saisonniers specifiques	Split temporel + monitoring continu
Biais de machine	Certaines machines peuvent etre surrepresentees	Verification de la distribution par machine_id
Biais de capteur	Des capteurs defaillants peuvent introduire du bruit	Preprocessing et detection d'outliers
Biais de selection	Le dataset peut ne pas couvrir tous les types de pannes	Enrichissement continu des donnees

Maintenance du Modele

Reexamen

- **Frequence** : Trimestrielle, ou apres tout changement significatif dans les donnees
- **Critere de reentrainement** : Baisse du F1-Score de plus de 5% par rapport a la baseline
- **Responsable** : Equipe Data MECHA

Monitoring en production

- Suivi du F1-Score sur les predictions en production
- Detection de concept drift (distribution des features)
- Alertes si le taux de faux negatifs depasse un seuil critique
- Comparaison periodique avec les maintenances reellement effectuees

Conformite EU AI Act

Exigence	Statut
Transparence du modele	Model card documentee

Exigence	Statut
Donnees d'entrainement documentees	Oui
Metriques de performance	Oui
Limites et biais documentes	Oui
Responsabilite humaine	Le modele est un outil d'aide a la decision
Classification de risque	Risque limite (industrie, pas de decision directe sur les personnes)

References

- MSPR 1 : Validation du Random Forest comme modele prioritaire (F1=71%)
- scikit-learn : https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html
- EU AI Act : https://eur-lex.europa.eu/eli/reg/2024/1689

Fiche Modele 2/5 — Model Card : XGBoost Classifier

Informations Generales

Champ	Valeur
Nom du modele	XGBoost Classifier
Version	1.0.0
Date de creation	2026-05-30
Framework	XGBoost (xgboost)
Type	Classification binaire (gradient boosting)
Statut	Modele alternatif
Projet	MECHA - MSPR 2, Bloc 4, EPSI RNCP35584

Description

Modele de classification binaire base sur le gradient boosting (XGBoost) pour la prediction de maintenance. XGBoost est une alternative au Random Forest offrant potentiellement de meilleures performances grace a l'apprentissage sequentiel et la regularisation integree.

Objectif

Predire si une machine necessite une intervention de maintenance (`maintenance_required = 1`) a partir des donnees capteurs IoT. Ce modele sert d'alternative au Random Forest pour comparer les approches.

Cas d'Usage Prevu

Utilisation principale

- **Maintenance predictive** : Alternative au Random Forest pour la detection de besoins de maintenance
- **Benchmark** : Comparaison des performances avec l'approche ensemble (Random Forest)
- **Production** : Peut remplacer le RF si les performances sont superieures

Utilisateurs cibles

- Equipe Data Science MECHA
- Responsables de maintenance (en cas de deploiement)

Hors perimetre

- Meme cadre que le Random Forest : outil d'aide a la decision, pas de decision autonome

Donnees d'Entrainement

Source

- **Dataset** : `mecha_dataset_processed.csv` (simulation MECHA + jeu public UCI AI4I 2020)
- **Volume** : 110 000 lignes de mesures capteurs IoT (88 000 train / 22 000 test)
- **Usines** : 5 sites MECHA (3 en France : Lyon, Toulouse, Nantes ; 2 en Espagne : Barcelone, Madrid)
- **Periode** : Donnees temporelles (Janvier - Mars 2025)

Split des donnees

- **Methode** : Split temporel 80/20 par source de donnees (identique au Random Forest)
- **Justification** : Coherence dans la comparaison des modeles

Features utilisees (10, capteurs uniquement)

Feature	Description	Type
`temperature`	Temperature machine (degres C)	Numerique
`vibration`	Niveau de vibration (mm/s)	Numerique
`humidity`	Taux d'humidite (%)	Numerique
`pressure`	Pression (bar)	Numerique
`energy_consumption`	Consommation energetique (kWh)	Numerique
`temp_rolling_10min`	Moyenne glissante temperature 10min	Numerique
`temp_trend_1h`	Tendance temperature 1h	Numerique
`vibr_rolling_10min`	Moyenne glissante vibration 10min	Numerique
`temp_std_30min`	Ecart-type temperature 30min	Numerique
`energy_vibr_ratio`	Ratio energie/vibration	Numerique

Features EXCLUES (data leakage)

Feature exclue	Raison
`machine_status`	**DATA LEAKAGE** confirme en MSPR 1 : cette variable encode directement l'etat de la machine et fuit l'information cible
`predicted_remaining_life`	**DATA LEAKAGE** identifie en revue MSPR 2 : dans la simulation, RUL = 500 x (1 - degradation) et la cible vaut 1 des que degradation > 0.6 ; la regle « RUL < 200 » reproduit la cible a 99 %
`downtime_risk`	**DATA LEAKAGE** : score composite construit a 45 % a partir du RUL

Desequilibre des classes

Classe	Proportion
0 (pas de maintenance)	~96.9%
1 (maintenance requise)	~3.1%

Gestion : `scale_pos_weight = n_negatifs / n_positifs` -- compense le desequilibre en augmentant le poids des positifs dans la fonction de cout.

Hyperparametres

Parametre	Valeur	Justification
`n_estimators`	200	Nombre d'arbres boosted
`max_depth`	8	Plus faible que RF car le boosting accumule la complexite
`learning_rate`	0.1	Taux d'apprentissage standard
`scale_pos_weight`	~31.3	Ratio negatifs/positifs pour compenser le desequilibre

Parametre	Valeur	Justification
`subsample`	0.8	Regularisation par sous-echantillonnage
`colsample_bytree`	0.8	Regularisation par selection de features
`reg_alpha`	0.1	Regularisation L1
`reg_lambda`	1.0	Regularisation L2
`eval_metric`	logloss	Metrique d'optimisation
`random_state`	42	Reproductibilite

Metriques de Performance

> Les metriques exactes sont generees automatiquement lors de l'entrainement et sauvegardees dans `models/evaluation/results/xgboost_metrics.json` .

Metrique	Valeur sur jeu de test (n = 22 000)	Description
Accuracy	**98.05 %**	Taux de predictions correctes
Precision	**74.76 %**	Ratio vrais positifs / (vrais positifs + faux positifs)
Recall	**88.64 %**	Ratio vrais positifs / (vrais positifs + faux negatifs)
F1-Score	**81.11 %**	Moyenne harmonique precision/recall (83.1 % sur MECHA simule)
AUC-ROC	**98.83 %**	Aire sous la courbe ROC

Avantages de XGBoost vs Random Forest

- Meilleure gestion des interactions complexes entre features
- Regularisation integree (L1, L2)
- Gestion native du desequilibre via `scale_pos_weight`
- Potentiellement plus performant sur les features a forte importance

Limites et Risques

Limites connues

1. **Complexite** : Plus difficile a interpreter que le Random Forest
2. **Sensibilite aux hyperparametres** : Necessite un tuning plus fin
3. **Temps d'entrainement** : Potentiellement plus long que le RF
4. **Surapprentissage** : Le boosting est plus sujet au surapprentissage si mal regularise
5. **Dependance externe** : Necessite la librairie xgboost (non incluse dans scikit-learn)

Risques

- Memes risques que le Random Forest (faux negatifs, faux positifs)
- Risque additionnel : complexite du modele rendant le debugging plus difficile

Biais Potentiels

Type de biais	Description	Mitigation
Biais temporel	Patterns saisonniers specifiques	Split temporel
Biais d'optimisation	Le boosting peut sur-optimiser certains patterns	Regularisation L1/L2, early stopping
Biais de machine	Surrepresentation de certaines machines	Monitoring par machine_id

Maintenance du Modele

Reexamen

- **Frequence** : Trimestrielle
- **Critere** : Comparaison continue avec le Random Forest
- **Responsable** : Equipe Data MECHA

Monitoring

- Suivi des metriques en production
- Comparaison periodique RF vs XGBoost
- Detection de derive (concept drift)

Conformite EU AI Act

Exigence	Statut
Transparence	Model card documentee
Donnees documentees	Oui
Metriques de performance	Oui
Limites et biais	Oui
Responsabilite humaine	Outil d'aide a la decision
Classification de risque	Risque limite

References

- XGBoost : https://xgboost.readthedocs.io/
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System
- EU AI Act : https://eur-lex.europa.eu/eli/reg/2024/1689

Fiche Modele 3/5 — Model Card : Random Forest Regressor (RUL)

Informations Generales

Champ	Valeur
Nom du modele	Random Forest Regressor (RUL)
Version	1.0.0
Date de creation	2026-05-30
Framework	scikit-learn
Type	Regression (prediction de la duree de vie restante)
Statut	Modele complementaire
Projet	MECHA - MSPR 2, Bloc 4, EPSI RNCP35584

Description

Modele de regression base sur un ensemble d'arbres de decision (Random Forest) pour la prediction de la duree de vie restante (RUL - Remaining Useful Life) des machines. Contrairement aux modeles de classification qui predisent SI une maintenance est necessaire, ce modele predit QUAND la maintenance sera necessaire en estimant le nombre d'unites de temps restantes avant defaillance.

Objectif

Estimer la valeur de `predicted_remaining_life` a partir des mesures capteurs (temperature, vibration, etc.), permettant une planification fine des interventions de maintenance.

Cas d'Usage Prevu

Utilisation principale

- **Planification de maintenance** : Estimer le temps restant avant intervention necessaire
- **Priorisation** : Classer les machines par urgence de maintenance
- **Optimisation des stocks** : Anticiper les besoins en pieces de rechange
- **KPI operationnel** : Fournir un indicateur continu de sante machine

Utilisateurs cibles

- Planificateurs de maintenance
- Responsables de production
- Tableaux de bord operationnels

Hors perimetre

- Ne predit PAS le type de defaillance
- Ne remplace PAS les modeles de classification pour la decision binaire de maintenance
- La prediction est une estimation, pas une certitude

Donnees d'Entrainement

Source

- **Dataset** : `mecha_dataset_processed.csv` (simulation MECHA + jeu public UCI AI4I 2020)
- **Volume** : 110 000 lignes (88 000 train / 22 000 test)
- **Usines** : 5 sites MECHA (3 en France, 2 en Espagne)
- **Variable cible** : `predicted_remaining_life` (0 a 500 minutes)

Split des donnees

- **Methode** : Split temporel 80/20 par source de donnees
- **Coherence** : Meme split que les modeles de classification

Features utilisees (10, capteurs uniquement)

Feature	Description	Type
`temperature`	Temperature machine	Numerique
`vibration`	Niveau de vibration	Numerique
`humidity`	Taux d'humidite	Numerique
`pressure`	Pression	Numerique
`energy_consumption`	Consommation energetique	Numerique
`temp_rolling_10min`	Moyenne glissante temperature	Numerique
`temp_trend_1h`	Tendance temperature	Numerique
`vibr_rolling_10min`	Moyenne glissante vibration	Numerique
`temp_std_30min`	Ecart-type temperature	Numerique
`energy_vibr_ratio`	Ratio energie/vibration	Numerique

Note : `predicted_remaining_life` est EXCLUE des features car c'est la variable cible.

Features EXCLUES

Feature exclue	Raison
`machine_status`	**DATA LEAKAGE**
`predicted_remaining_life`	Variable cible (pour ce modele)
`downtime_risk`	**DATA LEAKAGE** : construit a 45 % a partir de la cible (rul_risk = 1 - RUL/500)

Hyperparametres

Parametre	Valeur	Justification
`n_estimators`	200	Bon compromis performance/temps
`max_depth`	15	Limiter le surapprentissage
`min_samples_split`	10	Regularisation
`min_samples_leaf`	5	Regularisation
`max_features`	sqrt	Standard pour la regression ensemble

Parametre	Valeur	Justification
`random_state`	42	Reproductibilite

Metriques de Performance

> Sauvegardees dans `models/evaluation/results/rf_regressor_rul_metrics.json`.

Metriques de regression

Metrique	Valeur sur jeu de test (n = 22 000)	Description
MAE	**26.94 min**	Mean Absolute Error - erreur absolue moyenne sur echelle 0-500 min
RMSE	**46.36 min**	Root Mean Squared Error - racine de l'erreur quadratique moyenne
R2 Score	**0.7189 (71.9 %)**	Coefficient de determination (1 = parfait, 0 = modele naif)
MSE	**2149.08 min²**	Mean Squared Error

Interpretation

- **MAE** : En moyenne, l'erreur de prediction en **minutes** (echelle 0-500 min du jeu de donnees). Resultat : 26.9 min (R2 = 0.72)
- **R2** : Proportion de la variance de la RUL expliquee par le modele
- **RMSE** : Penalise davantage les grandes erreurs (utile pour les cas critiques)

Limites et Risques

Limites connues

1. **Precision de la RUL** : La variable cible (`predicted_remaining_life`) est elle-meme une estimation, pas une verite terrain mesuree
2. **Distribution de la RUL** : La plupart des valeurs de RUL sont elevees (machines en bon etat), le modele peut etre moins precis pour les faibles RUL
3. **Non-stationnarite** : Les patterns de degradation peuvent varier selon les types de machines et conditions
4. **Intervalle de confiance** : Le modele fournit une prediction ponctuelle sans intervalle de confiance

Risques

- **Surestimation de la RUL** : Dangereux, peut retarder une maintenance necessaire
- **Sous-estimation de la RUL** : Moins critique, mais genere des interventions prematurees
- **Confiance excessive** : Les utilisateurs pourraient accorder trop de confiance a une estimation ponctuelle

Biais Potentiels

Type de biais	Description	Mitigation
Biais de distribution	RUL souvent elevee, sous-representation des faibles RUL	Enrichissement des donnees de degradation

Type de biais	Description	Mitigation
Biais de machine	Degradation differente selon le type de machine	Features de contexte (machine_profile) possibles
Biais de capteur	Precision variable des capteurs	Preprocessing et validation des donnees
Biais de label	La RUL cible est estimee, pas mesuree	Documentation de la methode de calcul de RUL

Maintenance du Modele

Reexamen

- **Frequence** : Trimestrielle
- **Critere** : Comparaison MAE predite vs MAE sur les nouvelles donnees
- **Responsable** : Equipe Data MECHA

Monitoring

- Suivi de l'erreur de prediction en production
- Comparaison avec les durees de vie reelles observees
- Detection de derive dans la distribution des predictions

Conformite EU AI Act

Exigence	Statut
Transparence	Model card documentee
Donnees documentees	Oui
Metriques de performance	Oui (metriques de regression)
Limites et biais	Oui
Responsabilite humaine	Outil de planification, validation humaine requise
Classification de risque	Risque limite

References

- scikit-learn : https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html
- Saxena, A. et al. (2008). Damage propagation modeling for aircraft engine run-to-failure simulation
- EU AI Act : https://eur-lex.europa.eu/eli/reg/2024/1689

Fiche Modele 4/5 — Model Card : Isolation Forest

Informations Generales

Champ	Valeur
Nom du modele	Isolation Forest
Version	1.0.0
Date de creation	2026-05-30
Framework	scikit-learn
Type	Detection d'anomalies (non supervise)
Statut	Modele complementaire
Projet	MECHA - MSPR 2, Bloc 4, EPSI RNCP35584

Description

Modele de detection d'anomalies non supervise base sur l'Isolation Forest. Contrairement aux modeles de classification supervises (RF, XGBoost, LR), ce modele n'utilise PAS la variable cible `maintenance_required` pendant l'entrainement. Il identifie les points de donnees anormaux en mesurant leur facilite d'isolation dans un ensemble d'arbres aleatoires.

Principe de fonctionnement

Les anomalies sont des points de donnees qui sont faciles a isoler : ils necessitent moins de coupures aleatoires pour etre separes du reste des donnees. L'algorithme construit des arbres aleatoires et mesure la profondeur moyenne necessaire pour isoler chaque point.

Objectif

Detecter les comportements anormaux des machines (anomalies capteurs) qui pourraient indiquer un besoin de maintenance, sans necessite d'etiquettes historiques.

Cas d'Usage Prevu

Utilisation principale

- **Detection d'anomalies** : Identifier les comportements machines inhabituels
- **Surveillance continue** : Monitoring en temps reel des capteurs IoT
- **Alerte precoce** : Detection de degradation avant que les seuils classiques ne soient atteints
- **Complement** : Utilise en complement des modeles supervises

Utilisateurs cibles

- Systemes de monitoring en temps reel
- Equipes de maintenance pour les alertes de comportement anormal
- Equipe Data Science pour l'exploration de patterns inhabituels

Hors perimetre

- Ne fournit PAS de diagnostic (type de panne)
- Ne predit PAS la duree de vie restante
- Ne remplace PAS les modeles supervises pour la decision de maintenance

Donnees d'Entrainement

Source

- **Dataset** : `mecha_dataset_processed.csv` (simulation MECHA + jeu public UCI AI4I 2020)
- **Volume** : 88 000 lignes d'entrainement / 22 000 lignes de test (split temporel 80/20 sur 110 000 lignes, 5 sites FR/ES)
- **Particularite** : Entrainement NON supervise (pas de variable cible)

Features utilisees (10, capteurs uniquement)

Identiques aux autres modeles : `temperature`, `vibration`, `humidity`, `pressure`, `energy_consumption`, `temp_rolling_10min`, `temp_trend_1h`, `vibr_rolling_10min`, `temp_std_30min`, `energy_vibr_ratio`

Features EXCLUES

Feature exclue	Raison
`machine_status`	**DATA LEAKAGE**
`predicted_remaining_life`	**DATA LEAKAGE** (cible du modele RUL, quasi-equivalente a la cible de classification)
`downtime_risk`	**DATA LEAKAGE** (derive du RUL)

Hyperparametres

Parametre	Valeur	Justification
`n_estimators`	200	Nombre d'arbres pour la detection
`contamination`	0.05	Proportion attendue d'anomalies (5%)
`max_features`	1.0	Utiliser toutes les features
`random_state`	42	Reproductibilite

Note sur la contamination

La valeur de `contamination=0.05` est une estimation. Le taux reel de maintenance requise est de ~3.1%, mais les anomalies capteurs peuvent etre plus frequentes que les maintenances effectives. Ce parametre peut etre ajuste selon les retours terrain.

Metriques de Performance

> Sauvegardees dans `models/evaluation/results/isolation_forest_metrics.json`.

Metriques principales

Metrique	Valeur sur jeu de test (n = 22 000)	Description
Accuracy	**92.98 %**	Correspondance anomalies detectees vs maintenance reelle
Precision	**29.36 %**	Parmi les 1 226 anomalies detectees, part correspondant a une maintenance

Metrique	Valeur sur jeu de test (n = 22 000)	Description
Recall	**34.65 %**	Parmi les maintenances reelles, part detectee sans supervision
F1-Score	**31.79 %**	Moyenne harmonique (coherente pour un detecteur d'atypicite non supervise)
AUC-ROC	**83.86 %**	Discrimination sur le score continu `decision_function`
Contamination effective	**5.57 % (1 226 / 22 000)**	Taux reel d'anomalies signalees sur le jeu de test

Interpretation des metriques

Etant un modele non supervise, les metriques de classification sont calculees a posteriori en comparant les anomalies detectees avec `maintenance_required`. Un faible F1-Score n'indique pas necessairement un mauvais modele : les anomalies capteurs ne correspondent pas toujours a un besoin de maintenance.

Limites et Risques

Limites connues

1. **Non supervise** : Ne distingue pas les types d'anomalies (maintenance, erreur capteur, changement de production)
2. **Contamination fixe** : Le parametre `contamination` est une estimation qui peut ne pas refleter la realite
3. **Sensibilite aux outliers** : Des valeurs extremes non pertinentes peuvent etre classees comme anomalies
4. **Pas de probabilite** : Fournit un score d'anomalie, pas une probabilite calibree
5. **Correlation imparfaite** : Les anomalies detectees ne correspondent pas necessairement aux besoins de maintenance

Risques

- **Faux positifs excessifs** : Trop d'alertes d'anomalies creent de la fatigue d'alerte
- **Anomalies non pertinentes** : Certaines anomalies detectees sont des variations normales de production
- **Manque de contexte** : L'anomalie est detectee sans explication de la cause

Biais Potentiels

Type de biais	Description	Mitigation
Biais de normalite	Le modele apprend ce qui est "normal" a partir des donnees d'entrainement	Entrainement periodique avec des donnees recentes
Biais de contamination	Le parametre fixe peut sur/sous-estimer les anomalies	Ajustement base sur les retours terrain
Biais de feature	Certaines features peuvent dominer la detection d'anomalies	Analyse des scores d'anomalie par feature

Maintenance du Modele

Reexamen

- **Frequence** : Mensuelle (les patterns normaux evoluent)
- **Critere** : Taux de faux positifs en production
- **Responsable** : Equipe Data MECHA

Monitoring

- Suivi du taux d'anomalies detectees
- Correlation avec les maintenances effectuees
- Ajustement du seuil de contamination si necessaire
- Detection de derive dans la distribution des scores d'anomalie

Conformite EU AI Act

Exigence	Statut
Transparence	Model card documentee
Donnees documentees	Oui
Metriques de performance	Oui (avec reserve sur l'interpretation)
Limites et biais	Oui
Responsabilite humaine	Outil d'alerte, validation humaine requise
Classification de risque	Risque limite (alerte, pas de decision autonome)

References

- Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation Forest
- scikit-learn : https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html
- EU AI Act : https://eur-lex.europa.eu/eli/reg/2024/1689

Fiche Modele 5/5 — Model Card : Regression Logistique

Informations Generales

Champ	Valeur
Nom du modele	Regression Logistique
Version	1.0.0
Date de creation	2026-05-30
Framework	scikit-learn
Type	Classification binaire (modele lineaire)
Statut	Baseline de reference
Projet	MECHA - MSPR 2, Bloc 4, EPSI RNCP35584

Description

Modele de classification binaire lineaire servant de **baseline de reference** pour le projet MECHA. La regression logistique est un modele simple et interpretable qui permet d'etablir un seuil minimal de performance que les modeles plus complexes (Random Forest, XGBoost) doivent depasser.

Objectif

Fournir une baseline de performance pour la classification de maintenance. Si les modeles complexes ne depassent pas significativement la regression logistique, cela indique un probleme dans les features ou les donnees.

Cas d'Usage Prevu

Utilisation principale

- **Baseline** : Reference de performance minimale
- **Interpretabilite** : Comprendre les relations lineaires entre features et cible
- **Validation** : Verifier que les modeles complexes apportent une reelle valeur ajoutee

Utilisateurs cibles

- Equipe Data Science MECHA
- Parties prenantes necessitant une explication simple du modele

Hors perimetre

- Non prevu pour le deploiement en production (sauf si performances superieures)

Donnees d'Entrainement

Source

- **Dataset** : `mecha_dataset_processed.csv` (simulation MECHA + jeu public UCI AI4I 2020)
- **Volume** : 110 000 lignes (88 000 train / 22 000 test)
- **Usines** : 5 sites MECHA (3 en France, 2 en Espagne)
- **Split** : Temporel 80/20 par source de donnees (identique aux autres modeles)

Preprocessing specifique

- **StandardScaler** : Normalisation des features (moyenne=0, ecart-type=1)
- **Justification** : La regression logistique est sensible a l'echelle des features (contrairement aux arbres de decision)

Features utilisees (10, capteurs uniquement)

Feature	Description	Type
`temperature`	Temperature machine (degres C)	Numerique
`vibration`	Niveau de vibration (mm/s)	Numerique
`humidity`	Taux d'humidite (%)	Numerique
`pressure`	Pression (bar)	Numerique
`energy_consumption`	Consommation energetique (kWh)	Numerique
`temp_rolling_10min`	Moyenne glissante temperature 10min	Numerique
`temp_trend_1h`	Tendance temperature 1h	Numerique
`vibr_rolling_10min`	Moyenne glissante vibration 10min	Numerique
`temp_std_30min`	Ecart-type temperature 30min	Numerique
`energy_vibr_ratio`	Ratio energie/vibration	Numerique

Features EXCLUES (data leakage)

Feature exclue	Raison
`machine_status`	**DATA LEAKAGE** confirme en MSPR 1 : cette variable encode directement l'etat de la machine et fuit l'information cible
`predicted_remaining_life`	**DATA LEAKAGE** identifie en revue MSPR 2 : dans la simulation, RUL = 500 x (1 - degradation) et la cible vaut 1 des que degradation > 0.6 ; la regle « RUL < 200 » reproduit la cible a 99 %
`downtime_risk`	**DATA LEAKAGE** : score composite construit a 45 % a partir du RUL

Desequilibre des classes

Gestion : `class_weight='balanced'`

Hyperparametres

Parametre	Valeur	Justification
`C`	1.0	Force de regularisation par defaut
`class_weight`	balanced	Gestion du desequilibre
`solver`	lbfgs	Optimiseur quasi-Newton, efficace pour les petits/moyens datasets
`max_iter`	1000	Assurer la convergence
`random_state`	42	Reproductibilite

Metriques de Performance

> Sauvegardees dans `models/evaluation/results/logistic_regression_metrics.json`.

Metrique	Valeur sur jeu de test (n = 22 000)	Description
Accuracy	**71.43 %**	Taux de predictions correctes
Precision	**13.36 %**	Vrais positifs / predictions positives (nombreux faux positifs lineaires)
Recall	**92.01 %**	Vrais positifs / reels positifs
F1-Score	**23.33 %**	Moyenne harmonique (demontre le gain massif de RF 80.4 % et XGBoost 81.1 %)
AUC-ROC	**89.47 %**	Discrimination du modele

Interpretation des coefficients

La regression logistique permet d'interpreter directement l'influence de chaque feature : - Coefficient positif : augmente la probabilite de maintenance - Coefficient negatif : diminue la probabilite de maintenance - Magnitude : force de l'influence

Limites et Risques

Limites connues

1. **Linearite** : Suppose des relations lineaires entre features et log-odds de la cible
2. **Interactions** : Ne capture pas les interactions complexes entre features sans feature engineering
3. **Non-linearites** : Performances limitees si les patterns sont non-lineaires
4. **Performance attendue** : Inferieure aux modeles ensemble (RF, XGBoost) sur des donnees complexes

Risques

- **Sous-performance** : Peut ne pas detecter suffisamment de cas de maintenance
- **Simplicite excessive** : Les relations capteurs-maintenance sont probablement non-lineaires

Biais Potentiels

Type de biais	Description	Mitigation
Biais de linearite	Le modele ne capture que les relations lineaires	Utiliser comme baseline, pas comme modele principal
Biais d'echelle	Sensible a la normalisation	StandardScaler applique
Biais de features	Features multicollineaires peuvent affecter les coefficients	Verification VIF possible

Maintenance du Modele

Reexamen

- **Frequence** : A chaque reentrainement des modeles principaux
- **Role** : Verifier que les modeles complexes restent superieurs a la baseline

- **Responsable** : Equipe Data MECHA

Conformite EU AI Act

Exigence	Statut
Transparence	Modele le plus interpretable
Donnees documentees	Oui
Metriques de performance	Oui
Limites et biais	Oui
Classification de risque	Risque limite (baseline, pas de deploiement autonome)

References

- scikit-learn : https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html
- EU AI Act : https://eur-lex.europa.eu/eli/reg/2024/1689